

Slot17 – Giới thiệu về AI

- Tự build 1 model AI hỗ trợ các công ty

=> mỗi 1 công ty sẽ có 1 model riêng

=====

=> offline chạy trên server công ty

=> Cấu trúc

+ Giao diện: Viết bằng Nodejs (Express), React Native

+ AI Backend: python (FastAPI, LangChain, Ollama)

+ Model: phi3 hoặc llama3 (cài qua Ollama)

=== Dự kiến tối thiểu 20GB===

React AI Demo

web

server.js

package.json

public

index.html

ai

main.py # FastAPI AI Backend

requirements.txt

=====

Thư viện

B1 = Cài Ollama và Model AI

brew install ollama

ollama pull phi3 #llama3

Cài xong thì khởi động Ollama:

ollama serve

=====

Mô hình 2:

Sử dụng Gemini API Key => train để Gemini hiểu các tài liệu mà chúng ta cung cấp

=> hiện nay Gemini chưa cho fine-tune trực tiếp như GPT, Claude

Nhưng: cho phép xây dựng 1 lớp “kiến thức riêng” bằng kỹ thuật RAG (Retrieval-Augmented Generation)

===

Cấu trúc

React Native => Backend (Nodejs) => Python Service

+ Trích xuất dữ liệu (PyMuPDF)

+ Tạo embedding (Google Text Embedding API)

+ Lưu dữ liệu (FAIS hoặc ChromaDB)

=> Gemini API:

+ Nhận prompt (câu hỏi, tài liệu trích dẫn)

+ Sinh câu trả lời theo ngữ cảnh

=====

Các bước triển khai với Gemini:

B1- Cài

npm install express body-parser axios

pip install PyMuPDF chromadb google-generativeai

=====